

Local + API ou tudo via API?

A pergunta é se, com muitos usuários, vale eliminar os modelos locais e mandar tudo para uma API multimodal — trocando custo de máquina por custo de token.

O achado que muda a conta

Medi quanto do processamento local é ffmpeg e quanto são os modelos. A divisão é desfavorável ao argumento de tirar os modelos:

Etapa	Tipo	Tempo (3h07)
Detecção de cena	ffmpeg	63 s
Corte dos cliques de evidência	ffmpeg	60 s
Recortes de câmera	ffmpeg	47 s
Extração de quadros e recortes	ffmpeg	44 s
Subtotal ffmpeg	inevitável	214 s — 69%
Silero (áudio)	modelo	49 s
YuNet (rostos)	modelo	31 s
YOLOX (objetos)	modelo	16 s
Subtotal modelos	substituível	96 s — 31%

Tirar todos os modelos locais economiza 31% da máquina — e a máquina continua necessária.

Decodificar o vídeo, extrair quadros e cortar os trechos de evidência é ffmpeg, e nenhuma API faz isso por você. O produto promete que toda afirmação leva ao trecho de vídeo; esses trechos precisam ser cortados em algum lugar.

Medição direta: um recorte de câmera custa **42 ms de ffmpeg** e **28 ms de YuNet**. O modelo é a parte barata.

Três arquiteturas, custo por gravação de 3h

Arquitetura	API	Máquina	Total	Qualidade
Híbrido (atual)	US\$ 0,11	214 s + 96 s	US\$ 0,15	lê a URL
Tudo via API, em quadros	US\$ 0,48	214 s	US\$ 0,52	lê a URL
Tudo via API, vídeo nativo	US\$ 0,36	~60 s (clipes)	US\$ 0,37	perde a URL

Vídeo nativo no Gemini custa ~100 tokens por segundo em baixa resolução e ~300 em alta. Três horas dão 1,4 milhão de tokens em baixa — já acima da janela de contexto, o que obriga a fatiar a gravação.

O problema de qualidade do vídeo nativo

Este é o ponto que decide, e não é de custo. A evidência mais forte da análise é a **URL na barra de endereço** — foi ela que identificou chat.deepseek.com, chatgpt.com e a busca no Google. É texto minúsculo.

Já comprovei nesta base que um quadro reduzido a 1024 px **perde a URL**: precisei enviar um recorte da barra de endereço em resolução nativa para o modelo conseguir ler. O modo de vídeo nativo amostra a 1 quadro por segundo e reduz a resolução — exatamente o que destrói esse sinal. Em baixa resolução a URL é ilegível, e

em alta o custo triplica e ainda não há como recortar a barra.

Economia de escala

Uma máquina de 8 vCPU processa cerca de 5.000 gravações de 3h por mês a 70% de ocupação. Custo de referência: US\$ 53/mês em provedor de vCPU dedicada.

Volume/mês	Máquinas	Custo máquina	API	Total	Por gravação
100	1 pequena	US\$ 26	US\$ 11	US\$ 37	US\$ 0,37
1.000	1	US\$ 53	US\$ 110	US\$ 163	US\$ 0,16
10.000	2	US\$ 106	US\$ 1.100	US\$ 1.206	US\$ 0,12
50.000	10	US\$ 530	US\$ 5.500	US\$ 6.030	US\$ 0,12

A partir de mil gravações por mês a API domina a conta, não as máquinas. Em dez mil por mês as máquinas são 9% do total. Tirar os modelos locais para economizar máquina ataca a menor parte do problema — e sobe a parte maior, porque é justamente a assinatura da tela que filtra 43% das chamadas.

Tráfego

Os quadros enviados à API somam **27 MB por gravação** — medido, não estimado: 31 KB por quadro. O vídeo de origem tem 810 MB. Mandar o vídeo inteiro para a API multiplica o tráfego por **30**.

Volume/mês	Só os quadros	Vídeo inteiro
1.000	26 GB	791 GB
10.000	262 GB	7,7 TB

Onde a API realmente ganha

O argumento operacional é legítimo e os números acima não o capturam: máquina significa provisionar, monitorar, atualizar e lidar com falha. Isso tem custo humano que não aparece em dólar por gravação.

E em volume baixo a conta se inverte: com 100 gravações por mês, a máquina é 70% do custo e fica ociosa quase o tempo todo. Abaixo de algumas centenas por mês, pagar por token e não manter servidor é defensável.

Recomendação

Manter o híbrido. Não porque os modelos locais sejam baratos — e sim porque a máquina é inevitável de qualquer forma, e os modelos custam 31% dela enquanto cortam a conta de API em mais do que isso.

O caminho para escalar não é tirar os modelos: é **gastar menos API por gravação**. As alavancas, em ordem de retorno: Batch API corta 50%; cache de prompt reduz a entrada repetida; a assinatura da tela já filtra 43% e melhora com mais exemplares; e o OCR local da barra de endereço substituiria parte das chamadas de visão por leitura determinística e gratuita.

Ressalvas

- A divisão ffmpeg/modelos é **medida**. As projeções de volume são estimativa: nunca rodei este pipeline em produção nem em máquina de nuvem.

- A vazão de 5.000 gravações por máquina assume gravações de 3h. Provas mais curtas mudam tudo para melhor.
- Preços de máquina são de provedor de vCPU dedicada. Em AWS sob demanda, o custo de máquina dobra ou triplica e o argumento da API melhora.
- O custo de vídeo nativo supõe uma passada só. Fatiar a gravação para caber na janela de contexto pode repetir contexto e aumentar a conta.