

Modelos, tempo e custo

Plataforma de análise de integridade de avaliações — o que roda, quanto demora, quanto custa e em que máquina.

Os modelos

Quatro modelos. Três rodam na própria máquina, sem rede e sem custo por uso. Só a classificação de tela depende de API.

Modelo	Função	Tamanho	Licença	Onde roda
gemini-3.1-flash-lite	Identifica o que está na tela nos desvios	—	API Google	Nuvem
silero_vad.onnx	Detecta presença de voz humana	2,2 MB	MIT	Local
yunet.onnx	Detecta rostos, contagem e orientação da cabeça	0,2 MB	Apache-2.0	Local
yolox.onnx	Detecta objetos na região da câmera	34,2 MB	Apache-2.0	Local

Os três modelos locais somam **36,6 MB** e ficam versionados junto do projeto. Nenhum exige GPU.

Tempo medido, gravação de 3h07

Etapa	O que faz	Tempo
Detecção de cena	Varre o vídeo e acha as trocas de contexto (1.353 encontradas)	63 s
Extração de quadros	220 quadros + recorte da barra de endereço, a 31 ms cada	14 s
Assinatura da prova	Compara cada quadro com a tela da avaliação	20 s
Áudio (Silero)	Extrai e analisa 3h de áudio	51 s
Câmera (YuNet)	1.124 amostras a cada 10 s	79 s
Objetos (YOLOX)	187 amostras a cada 60 s	22 s
Fundo virtual	Compara trechos do fundo ao longo da gravação	1 s
Corte dos trechos	Um clipe de evidência por evento	60 s
Subtotal local	Tudo acima, sem depender de rede	≈ 5 min
Modelo de visão	≈ 125 desvios em 21 lotes, sujeito à fila da API	≈ 10 min

Total aproximado: 15 minutos para uma gravação de 3 horas. Dois terços do tempo é espera pela API, não processamento. Nas medições houve respostas 503 da API que multiplicaram esse tempo — o pipeline tenta de novo com espera crescente.

Custo

Só a classificação de tela tem custo por uso. Áudio, câmera, objetos e fundo virtual rodam na máquina e custam apenas o tempo de CPU.

Como a conta é feita

Item	Quantidade	Preço	Subtotal
Imagens enviadas	250 (125 desvios x 2 imagens)	1.120 tokens cada	280.000 tokens
Instrução e prompt	21 lotes	~600 tokens cada	12.600 tokens
Entrada total	292.600 tokens	US\$ 0,25 / milhao	US\$ 0,073
Saída (JSON)	~180 tokens por quadro	US\$ 1,50 / milhao	US\$ 0,034

≈ **US\$ 0,11 por gravação de 3 horas** — cerca de R\$ 0,60. Mil gravações custariam algo em torno de US\$ 110.

A assinatura da tela da prova derruba esse valor. Sem ela, os 220 quadros amostrados iriam todos para a API e o custo subiria para cerca de **US\$ 0,18** — a filtragem economiza aproximadamente 40%.

Preços do Gemini 3.1 Flash-Lite consultados em setembro de 2026: US\$ 0,25 por milhao de tokens de entrada, US\$ 1,50 de saída, 1.120 tokens por imagem. É um cálculo, não uma fatura — o valor real depende do tamanho das imagens e deve ser conferido no painel de faturamento.

Máquina necessária

Medições feitas em **Apple M4, 10 núcleos, 16 GB de RAM**, macOS 26.4. Nada aqui usa GPU: todos os modelos rodam em CPU pelo onnxruntime.

Recurso	Mínimo	Confortável	Por quê
Núcleos	4	8 ou mais	ffmpeg e onnxruntime paralelizam; menos núcleos aumentam o tempo proporcionalmente
RAM	8 GB	16 GB	3h de áudio ocupam 659 MB em memória de uma vez; com o Node em volta, o pico fica perto de 2 GB
Disco	50 GB	200 GB	37 MB de modelos, 16 MB de saída por análise de 3h, mais as gravações de origem (800 MB cada)
GPU	nenhuma	nenhuma	Os quatro modelos foram escolhidos para rodar em CPU
Rede	estável	estável	Só para a API de visão; o resto é offline

O que instalar

ffmpeg (com fprobe), **Node.js 22** e as dependências do projeto. Os modelos ficam na pasta **modelos/**. Nenhum serviço externo além da API do Gemini.

Um Mac mini M4 ou um servidor Linux de 4 vCPU e 8 GB dão conta com folga. Como o gargalo é espera de rede e não CPU, uma máquina maior não reduz muito o tempo total.

Ressalvas sobre estes números

- As medições vêm de **uma máquina e uma gravação**. Outra resolução, outro codec ou um disco mais lento mudam os tempos.
- O tempo do modelo de visão é o menos previsível. Nas medições houve respostas 503 da API que multiplicaram a espera por mais de cinco vezes.
- A chave usada é de **tier restrito**: o gemini-pro-latest respondeu 429 por cota e o gemini-2.5-flash foi descontinuado durante o desenvolvimento. Volume real pede chave paga.

- O modelo de tela é **preview**. Modelos preview mudam e saem do ar sem aviso — é o componente mais frágil da lista.
- O consumo de memória do áudio cresce linear com a duração. Uma gravação de 6 horas ocuparia 1,3 GB de uma vez. Processar em blocos resolveria, e ainda não foi feito.